



APOCAL'IPSSI

TEMPLATE PERTURBATION · J2 (TECHNIQUE)

ADR : Architecture Decision Record

Tracer une décision technique majeure (format Michael Nygard étendu)

Projet EduTutor IA · Édition 2026 · Semaine immersive Scrum

Auteur : Mohamed Amine EL AFRIT · Licence CC BY-NC-SA 4.0

IDENTIFICATION DU DOCUMENT

À compléter par l'équipe avant chaque remise

Équipe n°	2
Membres	Danielle Jamila KOAGNE NGANKAM, Krishmini KULAKRISHNA, Wicramachine SERGIO, Houda OUADAH, Adja Fatou SAGNA, Mohammed DERKAOUI, Ousmane NDIAYE
Sprint concerné	J2 (Perturbation Technique)
Version	v2.0 (post-perturbation)
Date de remise	30/06/2026 13h00
Statut	Validé PO

💡 Convention de nommage du fichier : *equipe-02-ADR-0003-v2.0.docx*

Table des matières

 Une fois le document complété, faites clic droit sur la table ci-dessous puis « Mettre à jour les champs (ou touche F9) pour générer les liens.

Pourquoi cet artefact ?.....	5
1. Métadonnées.....	5
2. Contexte	6
2.1. Situation factuelle.....	6
2.2. Impact si on ne décide rien.....	6
2.3. Contraintes du projet.....	6
3. Options envisagées.....	7
4. Décision retenue.....	8
4.1. Justification du choix.....	8
4.2. Mesures de mitigation des inconvénients.....	8
5. Conséquences	9
5.1. Conséquences positives (gains mesurés).....	9
5.2. Conséquences négatives (coûts assumés)	9
6. À surveiller post-décision.....	10
 Grille d'auto-évaluation.....	11
 Références et conventions	12
Références incontournables.....	12
Références spécifiques à ce document.....	12
Convention de versionnement.....	12

PRÉAMBULE

Pourquoi cet artefact ?

Un ADR (Architecture Décision Record) est un document court qui trace une décision technique structurante du projet. Format inventé par Michael Nygard en 2011, devenu un standard de l'industrie. Permet à l'équipe (et aux successeurs) de comprendre pourquoi une décision a été prise, dans quel contexte, avec quelles alternatives écartées, et avec quelles conséquences assumées.

Ce modèle est prérempli avec un cas d'usage : la perturbation J2 (« la latence inacceptable »), qui force votre équipe à migrer le modèle LLM du backend. Vous adapterez les valeurs concrètes (chiffres mesurés, options évaluées) à votre situation.

 **Mode d'emploi** Un ADR pèse 1 à 2 pages maximum. Plus long, il dérive en compte-rendu et personne ne le lit. Format Nygard : Contexte → Décision → Conséquences. Les ADR sont numérotés (ADR-0001, ADR-0002...) et stockés dans /docs/adr/ du repo.

1. Métadonnées

 **Objectif.** Identifier l'ADR de manière unique et tracer son cycle de vie (statut, version, ADR remplacé).

 **Format attendu.** Table 7 lignes : Numéro · Titre · Statut · Date · Auteurs · Version · Supersedes (ADR remplacé). Le numéro suit la convention ADR-XXXX.

 **Bon exemple.** « Bon exemple. « ADR-0003 · Migration LLM Llama 3.1 8B → Llama 3.2 3B · Statut Accepté · 2026-06-30 · Équipe 2 · v1.0 · Supersedes ADR-0001 »

 **À éviter.** « Décision LLM. » (sans numéro, sans statut, sans date, impossible de retrouver)

Numéro	ADR-0003
Titre	Migration du modèle LLM par défaut : Llama 3.1 8B → Llama-3.2 3B
Statut	☐ Proposé · ☒ Accepté · ☐ Déprécié · ☐ Remplacé
Date	2026-06-30 14h30 (perturbation J2)
Auteurs	Équipe 2 complète (Danielle Jamila, Krishmini, Wicramachine, Houda, Adja Fatou, Mohammed, Ousmane)
Version	V2.0 (création), incrémenter si révision majeure
Supersedes	ADR-0002 (Choix initial Phi-3-mini en cadrage matinal)

2. Contexte

 **Objectif.** Décrire la situation factuelle qui appelle cette décision. Pas d'opinion, pas de solution avant l'heure : seulement le problème.

 **Format attendu.** 2 à 4 paragraphes : symptômes mesurés · impact utilisateur · contraintes du projet · que se passe-t-il si on ne décide rien.

 **Bon exemple.** « Latence p50 mesurée à 12,4 s sur 5 runs avec Llama 3.1 8B. PO juge inacceptable (cf. perturbation J2). Contrainte stack locale Ollama imposée, impossible de basculer sur API externe. »

 **À éviter.** « C'est lent. On change. » (intestable, pas de mesure, pas de contrainte explicitée)

2.1. Situation factuelle

Mardi 30 juin 2026 à 10h00, la perturbation J2 est révélée : la latence de génération d'un quiz de 10 QCM est jugée inacceptable. Mesures effectuées par l'équipe (script benchmark.sh, 5 runs, environnement Sprint 1) :

- Latence p50 (médiane) : 42,3 s
- Latence p95 : 51,2 s
- Modèle utilisé : Llama 3.1 8B via Ollama local (configuration ADR-0001)
- Ressenti utilisateur (testé sur 3 beta-testeurs) : « beaucoup trop long, j'abandonne »
- Métriques d'engagement : -34 % de quiz complétés vs session de référence

2.2. Impact si on ne décide rien

- MVP Release 1 (mercredi 17h45) risque d'être rejeté en démo PO pour cause d'UX dégradée
- Adoption B2B (Mme Lefèvre) compromise : 28 étudiants ne supportent pas 42 s d'attente
- Concurrents directs (Wilgo, Leo) annoncent des temps < 5 s, désavantage concurrentiel majeur
- Risque d'abandon massif en production : seuil d'abandon utilisateur mesuré à 15 s (étude Nielsen Norman)

2.3. Contraintes du projet

- Stack imposée : Ollama local uniquement, aucune API externe autorisée (OpenAI, Anthropic, Mistral cloud)
- Décision attendue avant la fin du Sprint 3 (mardi 18h), vitre de tir de ~6 h
- Maintien de la conformité RGPD (cf. différenciateurs Vision Board)
- RAM serveur limitée à 8 Go (contrainte matérielle)

3. Options envisagées

 **Objectif.** Lister exhaustivement les alternatives évaluées. Y compris celles écartées rapidement (pour montrer qu'on n'a pas oublié).

 **Format attendu.** Table 4 colonnes : Option · Avantages · Inconvénients · Coût (effort + risque). Au moins 3 options. Inclure l'option « ne rien faire » si pertinente.

 **Bon exemple.** « Phi-3-mini : 3,1 s p50, qualité 7,6/10 (vs 8,2 sur Llama). Coût migration faible (config Ollama). »

 **À éviter.** « On a regardé d'autres trucs. » (sans liste, sans chiffres)

Option	Avantages	Inconvénients	Coût (effort/risque)
A. Ne rien faire (statu quo Llama 3.1 8B)	0 effort, qualité de réponse maintenue (8,2/10)	42,3 s latence inacceptable, MVP risque rejet, abandon utilisateur	Faible effort / risque ÉLEVÉ sur démo PO
B. Optimiser le prompt seul (Llama 3.1 8B)	Pas de changement de stack, gain attendu ~20 %	Gain insuffisant (33,8 s p50 estimé), reste largement > 5 s	Faible effort / risque modéré (pas une vraie solution)
C. Migrer vers Llama 3.2 3B (CHOIX RETENU)	Latence 12,4 s p50 (-71 %), RAM -5 GB, même famille Meta (prompts compatibles), qualité 8,0/10 (-2 %)	Qualité légèrement inférieure à 8B, mais largement acceptable pour QCM pédagogiques	Effort FAIBLE (config Ollama 30 min) / risque qualité MINIME
D. Migrer vers Phi-3-mini (3,8B)	Latence 8,2 s p50 (-81 %), RAM -6 GB	Qualité 6,9/10 (-16 %), 4 questions ambiguës/50 vs 1/50, famille Microsoft (moins de cohérence prompts)	Effort faible / risque qualité ÉLEVÉ

4. Décision retenue

💡 **Objectif.** Annoncer clairement l'option choisie et justifier pourquoi celle-ci plutôt qu'une autre.

📄 **Format attendu.** 1 phrase d'annonce + 1 paragraphe justification + mention de la mesure de mitigation pour les inconvénients.

✅ **Bon exemple.** « Décision : Option C, Migration vers Llama 3.2 3B comme modèle LLM par défaut, avec feature flag pour rollback rapide vers Llama 3.1 8B si la qualité dégrade en production. »

❌ **À éviter.** « On essaye et on verra. » (Pas une décision, pas de critère de réversibilité)

Décision retenue : Option C - Migration vers Llama 3.2 3B comme modèle LLM par défaut, avec feature flag pour rollback rapide vers Llama 3.1 8B si la qualité dégrade en production.

4.1. Justification du choix

L'option C (Llama 3.2 3B) est retenue car elle offre le meilleur compromis qualité/latence parmi les options conformes à la stack imposée :

Latence ramenée à 12,4 s p50 (-71 %) : sous le seuil d'abandon utilisateur de 15 s

Qualité préservée à 8,0/10 (-2 % seulement) : largement au-dessus du seuil cible ≥ 7

Même famille Meta que Llama 3.1 8B : compatibilité des prompts existants, migration sans réécriture

RAM réduite de 5 GB (8B $\rightarrow$ 3B) : permet d'envisager plus d'utilisateurs simultanés

Option D (Phi-3-mini) écartée : perte de qualité trop importante (-16 %) et famille Microsoft moins cohérente

Option E (cloud) écartée : violation RGPD, non négociable pour la cible B2B éducation

4.2. Mesures de mitigation des inconvénients

- Feature flag LLM_MODEL en variable d'environnement : permet rollback en 5 minutes vers Llama 3.1 8B si problème
- Validation post-LLM systématique : parsing JSON strict du résultat (4 options, 1 correcte, longueur > 10 caractères), re-prompt automatique si invalide (max 2 essais)
- Audit qualité hebdomadaire : 50 quiz tirés au hasard, scoring manuel par 2 reviewers, KPI « % erreurs factuelles » suivi dans le dashboard
- Veille active des nouveaux modèles (Llama 3.3, Mistral Small 3.1, Phi-4), révision ADR si meilleur compromis identifié.

5. Conséquences

 **Objectif.** Lister honnêtement les conséquences positives ET négatives. Une décision qui n'a que des avantages est suspecte.

 **Format attendu.** 3 listes : Positives (gains mesurés) · Négatives (coûts assumés) · Atténuations (déjà détaillées en 4.2).

 **Bon exemple.** « Positif : latence p50 : 12,4 s → 3,1 s (-74 %). Négatif : qualité 8,2/10 → 7,6/10 (-7 %). »

 **À éviter.** « Que des avantages. » (Pas crédible, l'équipe n'a pas mesuré)

5.1. Conséquences positives (gains mesurés)

-  Latence p50 : 42,3 s → 12,4 s (gain 71 %)
-  Latence p95 : 51,2 s → 16,8 s (gain 67 %)
-  RAM serveur libérée : -5 GB (Llama 3.2 3B = 3B vs Llama 3.1 = 8B)
-  Coût électrique serveur : estimé -35 % (modèle plus petit)
-  Démo PO Sprint 5 sécurisée (latence sous 15 s pour 100 % des quiz)
-  Compatibilité prompts : même famille Meta, pas de réécriture nécessaire

5.2. Conséquences négatives (coûts assumés)

-  Qualité moyenne du quiz : 8,2/10 → 8,0/10 (perte 2 % seulement, acceptable)
-  Taux de questions ambiguës : 1/50 → 2/50 (× 2), nécessite validation renforcée
-  Dépendance accrue à la validation post-LLM (point de défaillance unique si bug parser)
-  Risque de re-migration si Llama 3.2 3B déprécié par Meta (sunset modèle)

6. À surveiller post-décision

 **Objectif.** Définir les indicateurs qui permettront de juger, dans 2-4 semaines, si la décision était bonne. Définir aussi les signaux qui déclencheraient un nouvel ADR.

 **Format attendu.** Table 4 colonnes : KPI · Seuil cible · Seuil d'alerte · Action si dépassement. 3 à 5 KPIs.

 **Bon exemple.** « Latence p50 · cible < 5 s · alerte > 8 s · action : déclencher ADR de re-migration »

 **À éviter.** « On regardera. » (pas de seuil, pas d'action, pas d'ADR de suivi)

KPI à surveiller	Seuil cible	Seuil d'alerte	Action si dépassement
Latence p50 génération quiz	< 15 s	> 20 s pendant 3 jours consécutifs	Déclencher ADR de re-migration (test Phi-4 ou Mistral Small 3.1)
Latence p95 génération quiz	< 20 s	> 25 s pendant 3 jours	Audit infrastructure Ollama + GPU si applicable
Score qualité moyen (audit hebdo 50 quiz)	≥ 7,8/10	< 7,5/10 sur 2 semaines	Améliorer prompt (few-shot exemples) + revue ADR
Taux d'échec validation post-LLM	< 5 %	> 10 % sur 1 semaine	Audit code parser + ajout règles de validation
Signalements utilisateurs (erreur factuelle)	< 2/semaine	> 5/semaine	Déclencher revue produit avec PO (cf. perturbation J4)

 **Date de revue planifiée de cet ADR :** 2 semaines après mise en production (soit semaine S+2 post-MVP), avec PO et équipe IA. Une re-décision implique un nouvel ADR-XXXX qui supersedes celui-ci.

☒ Grille d'auto-évaluation

À remplir par l'équipe avant de soumettre le livrable au Product Owner. Un livrable rempli avec « Partiel » sur plusieurs lignes signale un besoin de revue collective avant validation.

Critère qualité	Auto-évaluation	Commentaire / preuve
L'ADR a un numéro unique (ADR-XXXX) et un statut explicite (Accepté / Proposé / Remplacé)	☒ Oui	ADR-0002, statut Accepté
Le contexte décrit la situation factuelle avec des chiffres mesurés (pas d'opinion)	☒ Oui	Latence p50=42,3s, p95=51,2s, 5 runs
Au moins 3 options sont listées dans le tableau comparatif, incluant l'option « ne rien faire »	☒ Oui	4 options listées (A à D)
La décision retenue est annoncée en 1 phrase claire (pas d'ambiguïté)	☒ Oui	Option C : Llama 3.2 3B
La justification du choix s'appuie sur les critères du contexte (latence, qualité, contrainte stack)	☒ Oui	Compromis qualité/latence/stack
Les mesures de mitigation des inconvénients sont listées explicitement	☒ Oui	4 mesures : feature flag, validation, audit, veille
Les conséquences positives ET négatives sont chiffrées	☒ Oui	+71% latence, -2% qualité, -5GB RAM
Au moins 3 KPIs sont définis avec seuil cible + seuil d'alerte + action	☒ Oui	5 KPIs définis
Une date de revue de l'ADR est fixée (typiquement 2-4 semaines après décision)	☒ Oui	S+2 post-MVP

Références et conventions

Références incontournables

- **Cours Agile/Scrum (Mohamed EL AFRIT) :**
mohamedelafr.it.com/teaching/Master_Classe_Agile/cours.html
- **Scrum Guide officiel FR :** scrumguides.org/docs/scrumguide/v2020/2020-Scrum-Guide-French.pdf
- **Site APOCAL'IPSSI :** mohamedelafr.it.com/teaching/APOCALIPSSI

Références spécifiques à ce document

- **Michael Nygard, Documenting Architecture Decisions (article fondateur, 2011) :**
<https://cognitect.com/blog/2011/11/15/documenting-architecture-decisions>
- **ADR GitHub, Collection de modèles et exemples :**
<https://github.com/joelparkerhenderson/architecture-decision-record>
- **ThoughtWorks Tech Radar, ADR "Adopt":** <https://www.thoughtworks.com/en-us/radar/techniques/lightweight-architecture-decision-records>
- **APOCAL'IPSSI, Perturbation J2 (la latence inacceptable) :**
<https://mohamedelafr.it.com/teaching/APOCALIPSSI/pages/perturbations/j2-technique.php>

Convention de versionnement

- • v1.0, version initiale produite lors du cadrage matinal
- • v1.1, v1.2, révisions mineures (typo, ajout d'item) après revue PO
- • v2.0, révision majeure à la suite d'une perturbation (changement de scope)
- • Chaque version est committée séparément avec message Git explicite
- • Le statut « Validé PO » nécessite une trace écrite (commentaire, mail, Teams)